다층 퍼셉트론 조사 보고서

인공지능 입문 | 105

컴퓨터공학부
202012007 안지우

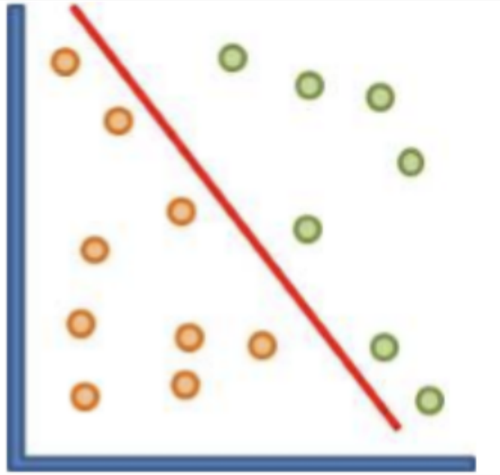
Contents

- 다층 퍼셉트론의 등장 배경
- 다층 퍼셉트론의 개념 및 구조
- 다층 퍼셉트론의 동작 원리
- 활성화 함수
- 역전파 알고리즘

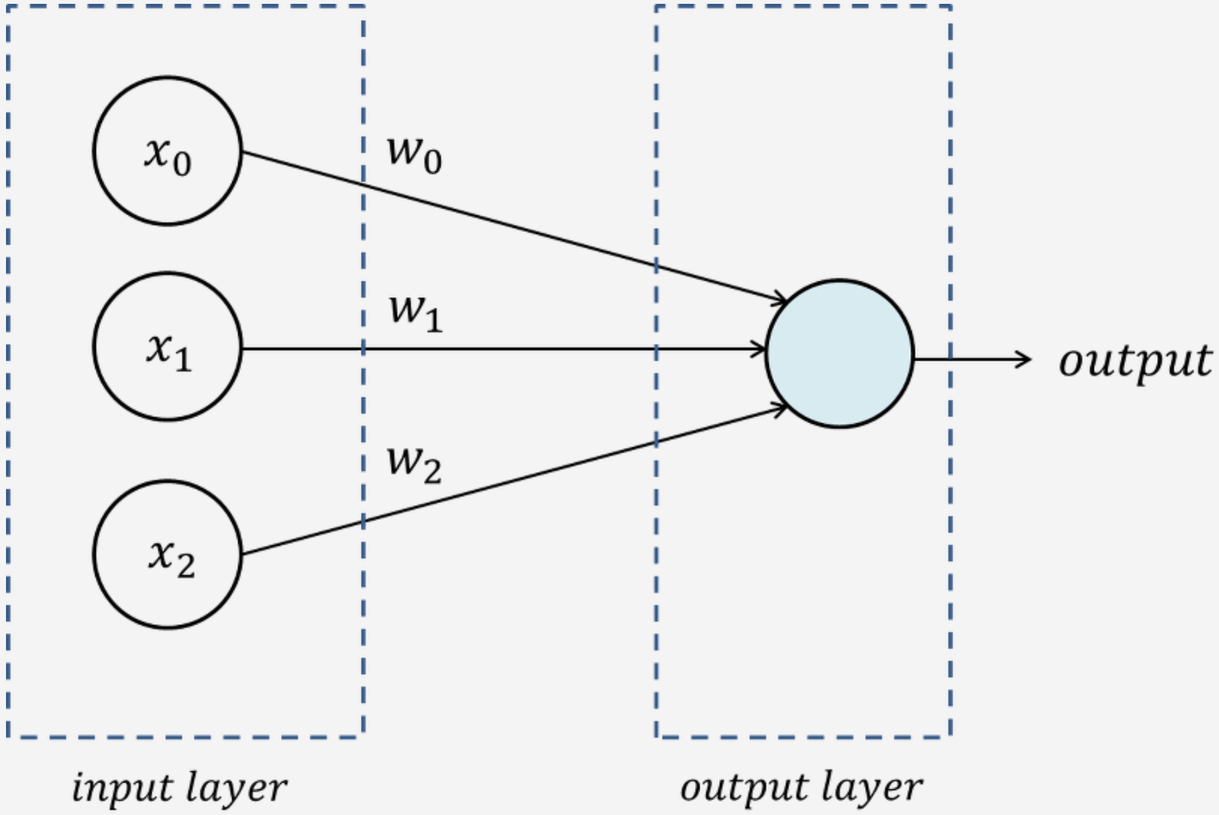
다층 퍼셉트론의 등장 배경

• 단층 퍼셉트론

- 1957년 로젠블럿에 의해 고안된 인공신경망 모델
- '입력층'과 '출력층'으로 구성되며, 입력된 데이터를 활성 함수와 가중치에 따라 연산한 다음 출력함
- 선형 분리 가증한 데이터에 대해서 뛰어난 성능을 보임



선형 분리 문제



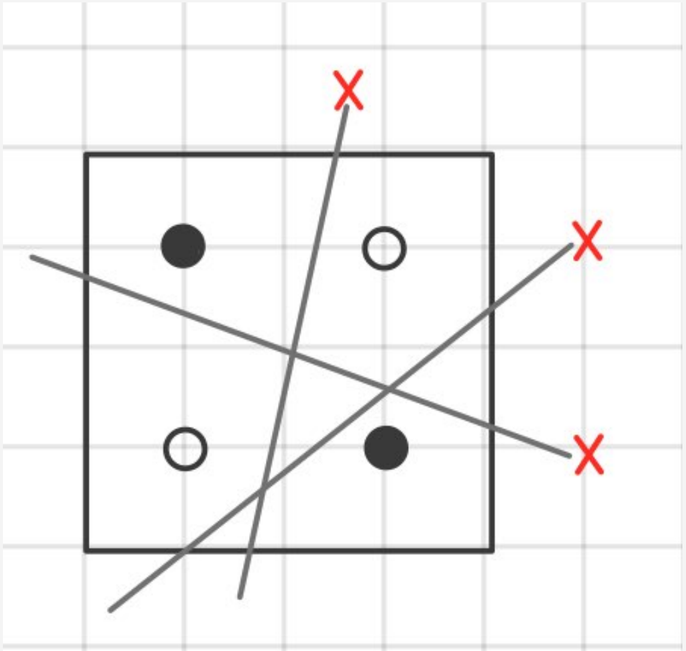
다층 퍼셉트론의 등장 배경

• 단층 퍼셉트론 - 한계점 XOR 문제

- 단층 퍼셉트론은 선형 분리가 불가능한 복잡한 문제 학습에 대해서는 제한적임
- 대표적인 문제가 XOR 문제

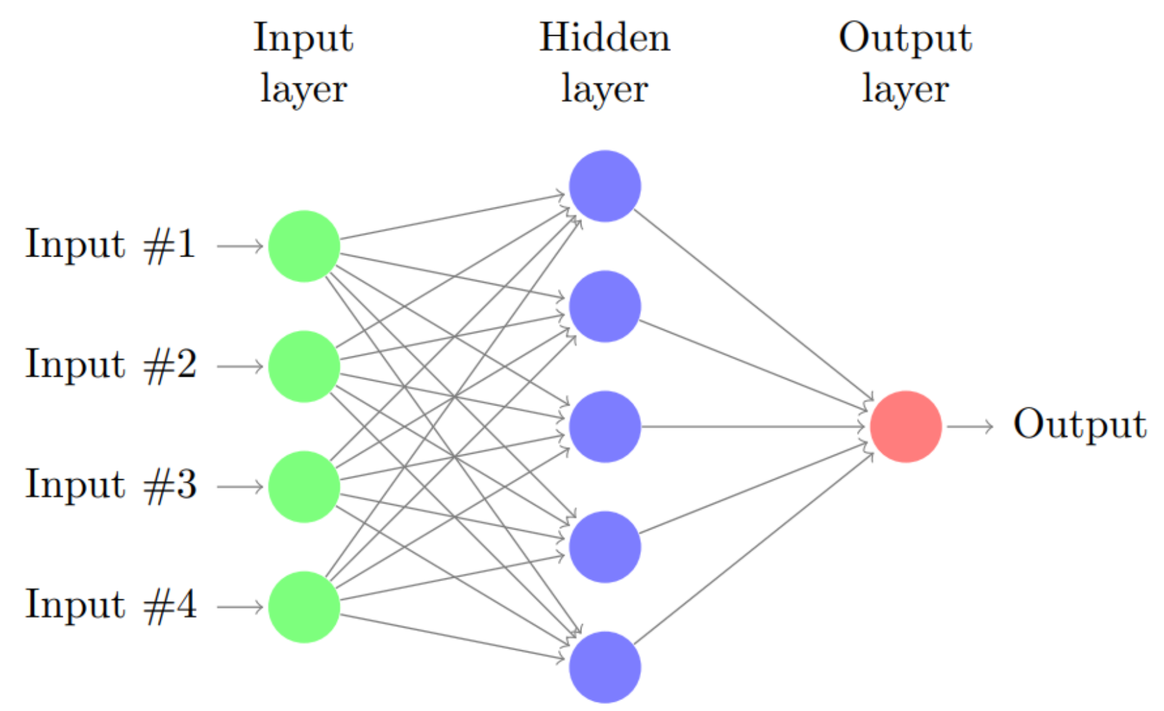
  → 하나의 직선으로 분포를 구분할 수 있음

층의 수를 늘린
‘다층 퍼셉트론 모델‘이
XOR 문제를 해결



XOR 문제

다층 퍼셉트론의 개념 및 구조



↑ **입력층**

입력값 전달

↑ **다수의 은닉층**

비선형적 변환

↑ **출력층**

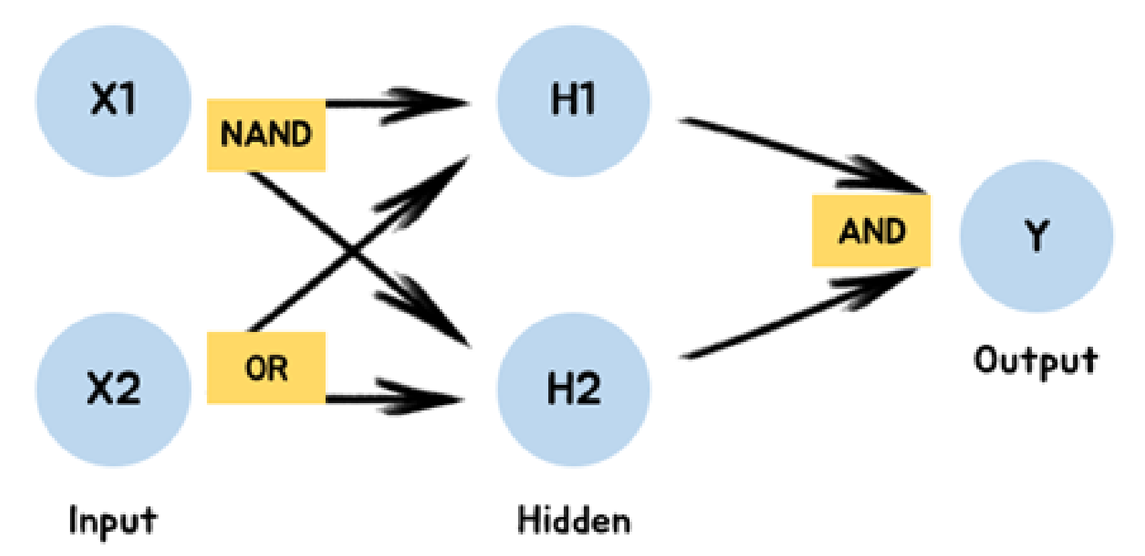
최종 결과 출력

- 다층 퍼셉트론은 하나의 퍼셉트론 위에 또 다른 퍼셉트론을 쌓은 모양을 하고 있음
- 다층 퍼셉트론의 경우 '입력층', '출력층' 그리고 그 사이 '은닉층'으로 구성됨
- 은닉층이 1개인 경우 **얕은 신경망**
- 은닉층이 2개 이상인 경우 **심층 신경망** 이라함
  → 은닉층이 많아질수록 복잡한 연산 수행 가능

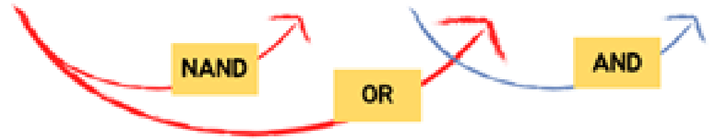
↓

다층 퍼셉트론이
어떻게 비선형 분리 문제인
XOR 문제를 해결할 수 있었을까?

다층 퍼셉트론의 개념 및 구조



전체 연산 Process				
X1	X2	H1	H2	Y
0	0	1	0	0
0	1	1	1	1
1	0	1	1	1
1	1	0	1	0



다층 퍼셉트론은 '은닉층'을 추가하고
입력값에 대해서 NAND 연산과 OR연산을 각각 수행한 후
최종적으로 AND 연산을 수행하여 최종적으로 XOR 연산의 결과를 얻을 수 있게 되었음

다층 퍼셉트론은 선형 영역을 넘어
비선형 영역까지도 표현할 수 있음을 증명함

다층 퍼셉트론의 동작 원리

- 퍼셉트론은 기본적으로 입력 값에 해서 가중치를 곱한 후에 더하는 **선형 계산**을 수행함

그러나, 선형 변환의 결과는 선형이기에
신경망의 모든 층이 선형 변환을 수행한다면
비선형 문제를 해결하지 못함

- 비선형 분리와 같은 복잡한 패턴을 학습하기 위해선 선형 데이터를 비선형으로 바꿔주는 계산을 수행해야함

→ 이러한 역할을 수행하는 것이 **활성화 함수**

$$L_1 = W_1 X + b_1$$
$$L_2 = W_2 L_1 + b_2$$

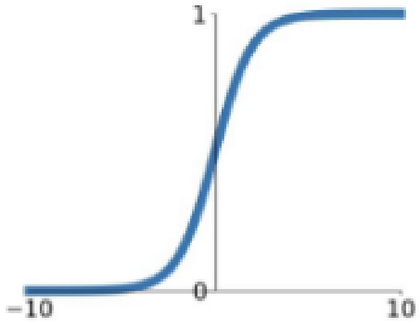
선형계산

$$\mathbf{H}_1 = \sigma(\mathbf{W}_1 \mathbf{X} + \mathbf{b}_1)$$
$$\mathbf{H}_2 = \sigma(\mathbf{W}_2 \mathbf{H}_1 + \mathbf{b}_2)$$
$$\mathbf{O} = \mathrm{softmax}(\mathbf{W}_3 \mathbf{H}_2 + \mathbf{b}_3)$$

비선형계산

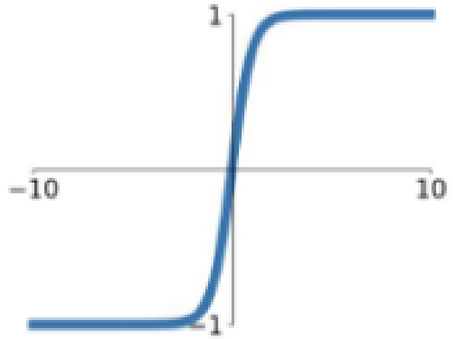
활성화 함수

- 어떤 문제를 해결하는 가에 따라 **서로 다른 활성화 함수**를 사용할 수 있음



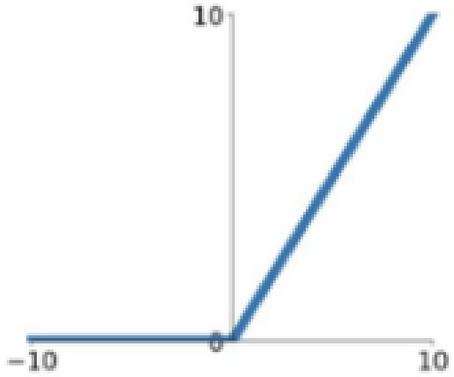
시그모이드 함수

$$\frac{1}{1+e^{-x}}$$



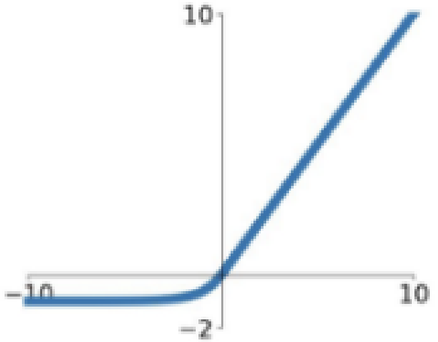
하이퍼볼릭 탄젠트

$$\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}$$



ReLU

$$\max(0,x)$$

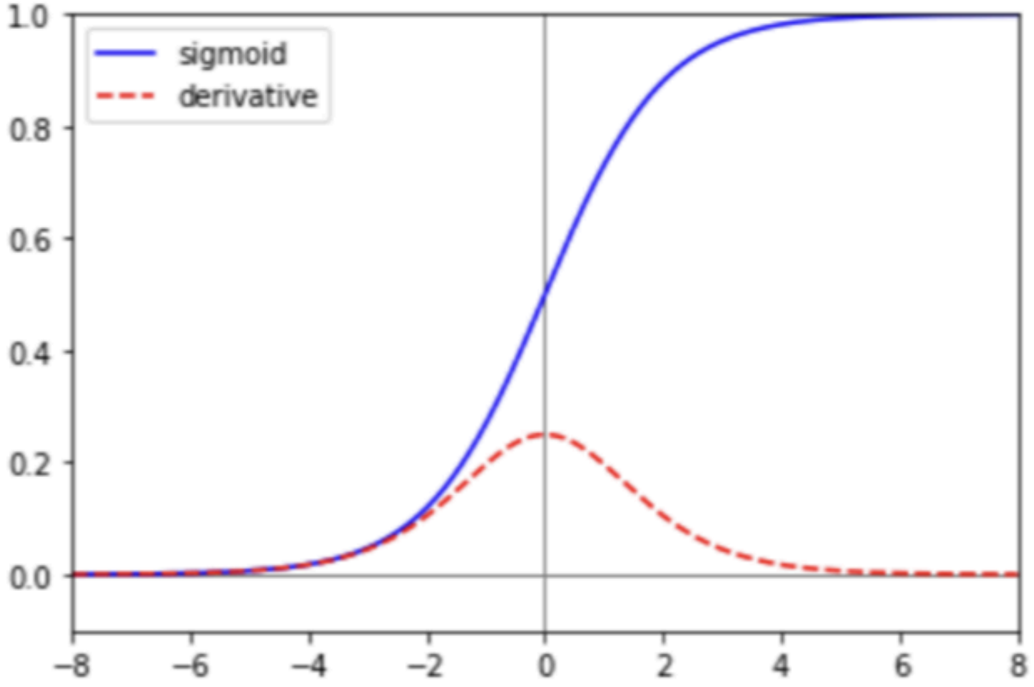


ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^{x}-1) & x < 0 \end{cases}$$

활성화 함수

- 시그모이드 함수



$$sigmoid(x) = \frac{1}{1 + e^{-x}}$$

- 입력으로 받은 값을 (0, 1) 로 바꿔주는 함수
- 시그모이드는 모든 실수를 입력 범위로 가지며, 일종의 스위치같은 역할을 수행함

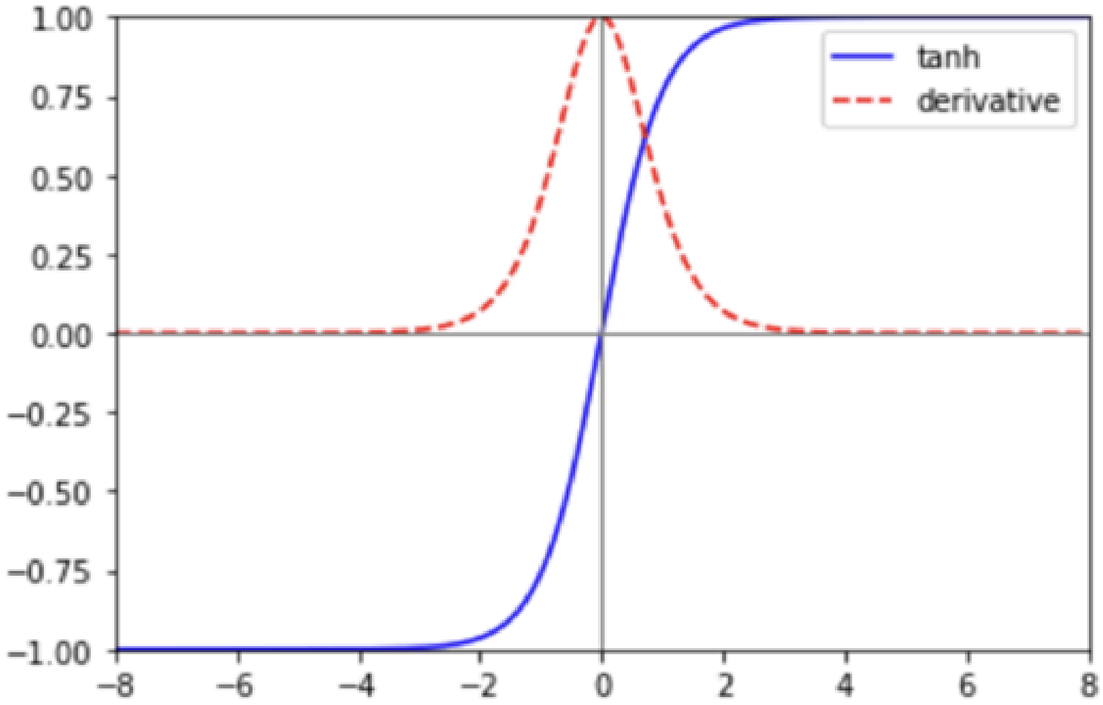
→ 사건의 발생 가능성을 예측하는 '로지스틱 회귀' 등의 모델에 적합한 활성화 함수임

단, 절대값이 큰 입력값에 대해서 기울기가 0으로 수렴하는 특징때문에, 경사하강법을 적용할 시 기울기가 0에 가까워져 소실되는 **기울기 소실 현상**이 발생함

층이 깊어질수록, 가중치를 제대로 갱신할 수 없어 딥러닝에서는 잘 사용하지 않는 함수

활성화 함수

- 하이퍼볼릭 탄젠트



$$tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

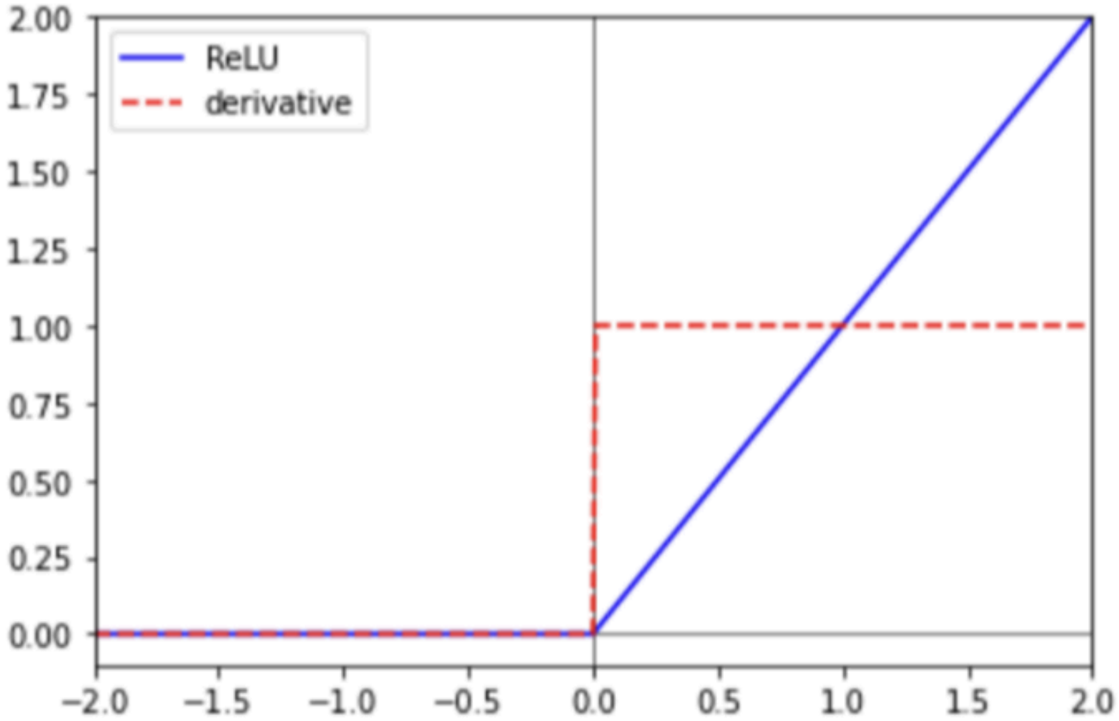
- 시그모이드 함수 형태를 가지는 기함수 꼴의 활성화 함수
- 입력값을 (-1, 1) 범위로 압축함

함수의 중심이 원점에 존재하기에 경사 하강법을 이용하여 가중치를 최적화할 때 sigmoid 함수보다 원활하게 동작함.

→ 여전히, 기울기 소실 문제가 존재함.

활성화 함수

- **ReLU**



$$ReLU(x) = \max(0, x)$$

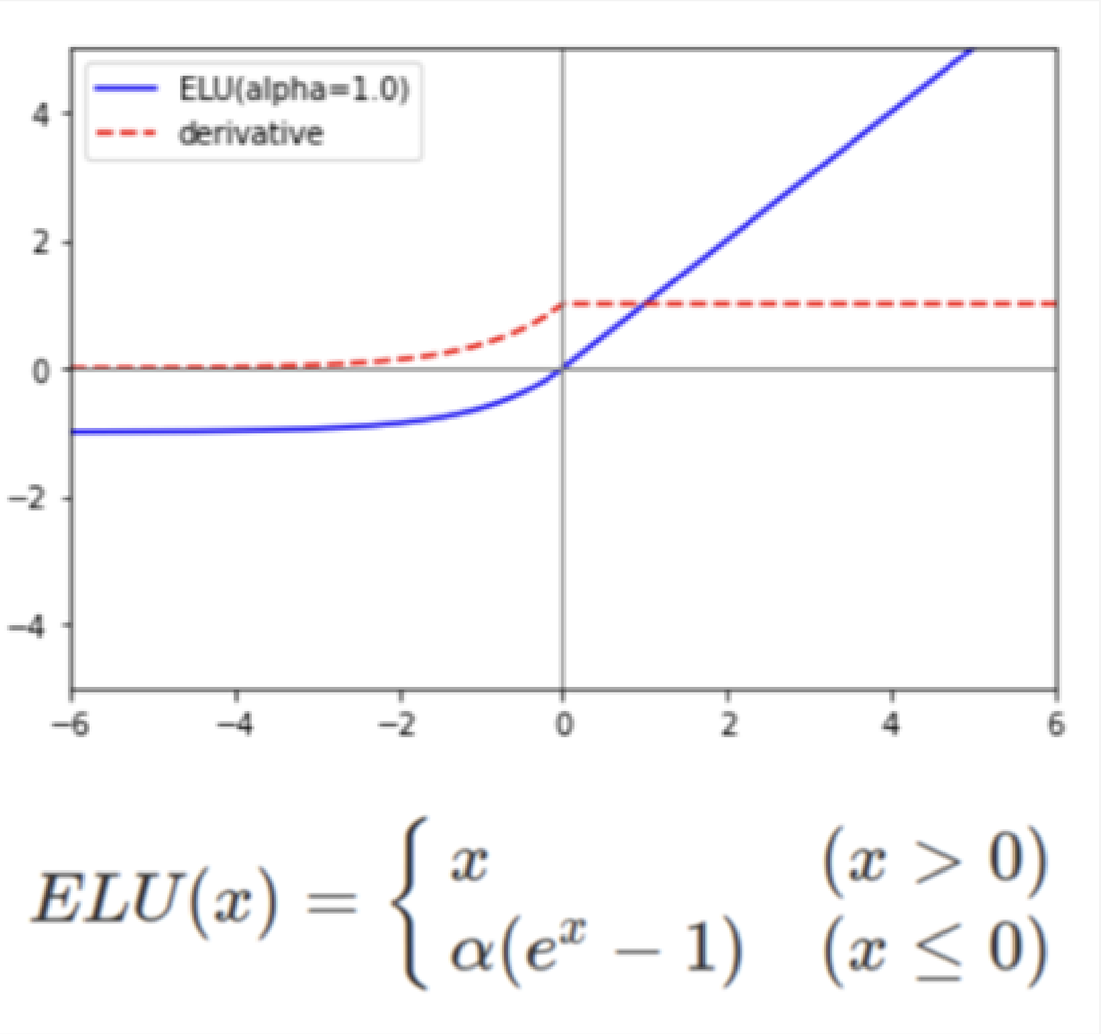
- 0보다 큰 입력에 대해서 그대로 출력함
- 0이하의 값은 다음 층으로 전달하지 않음
- 공식이 단순하기에 계산이 매우 빠름

음수의 입력값을 모두 0으로 반환하기 때문에
입력값이 한 번 이라도 음수가 나오면 가중치가 갱신되지 않은 **Dying ReLU**현상이 발생함

이러한 문제점 때문에,
0보다 작은 경우 약간의 변화량을 리턴하는
Leaky ReLU, PReLU 가 존재함

활성화 함수

- ELU



$$ELU(x) = \begin{cases} x & (x > 0) \\ \alpha(e^x - 1) & (x \leq 0) \end{cases}$$

- 음수 입력값을 지수 함수 형태로 정의함. 그래서 x값이 음수 방향으로 커지더라도 함숫값이 0에 가까운 일정한 음숫값으로 포화됨.

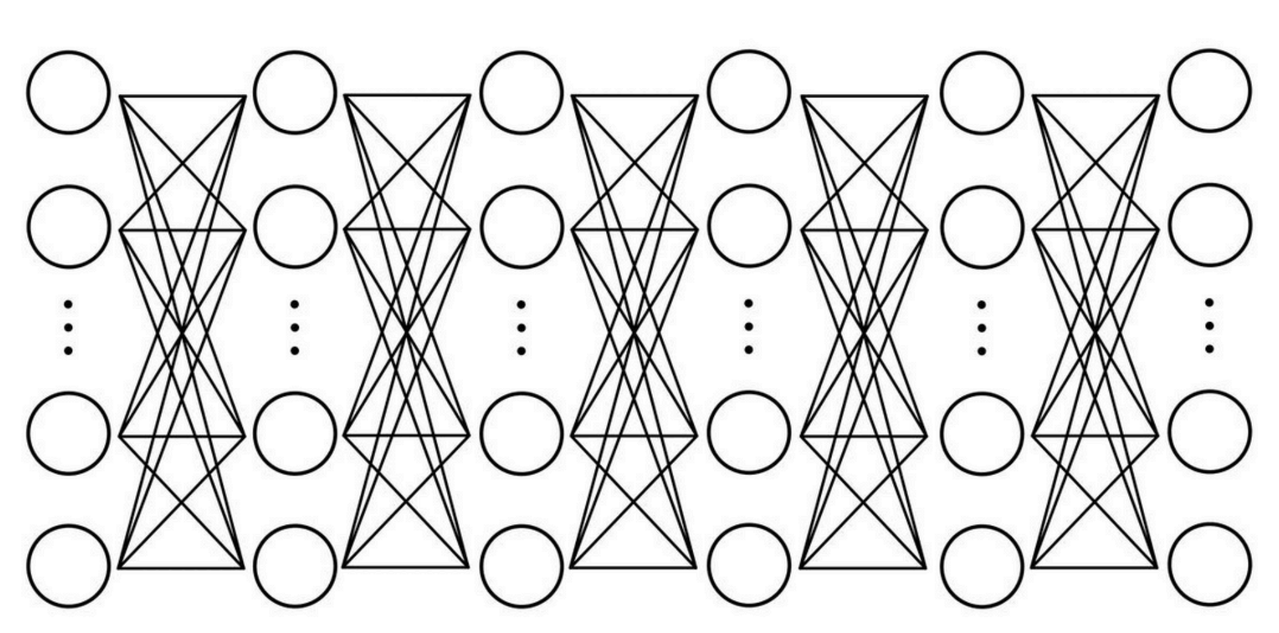
아주 큰 음수값이 입력되더라도 함수값이 커지지 않으므로 노이즈에 덜 민감함

알파 값에 따라, 포화 정도가 달리짐

ELU는 ReLU의 장점을 모두 가지며 dying ReLU를 해결한 함수

단, 음수 입력값에 대해서 지수함수 계산을 수행하기에 ReLU보다 연산량이 증가함

역전파 알고리즘



- 다층 퍼셉트론은 깊이가 깊어질수록, 모델의 가중치의 수는 기하급수적으로 늘어남.
- 이 경우 경사하강법을 통해서 모든 가중치를 갱신하면, 매우 많은 연산량과 매모리가 소모됨

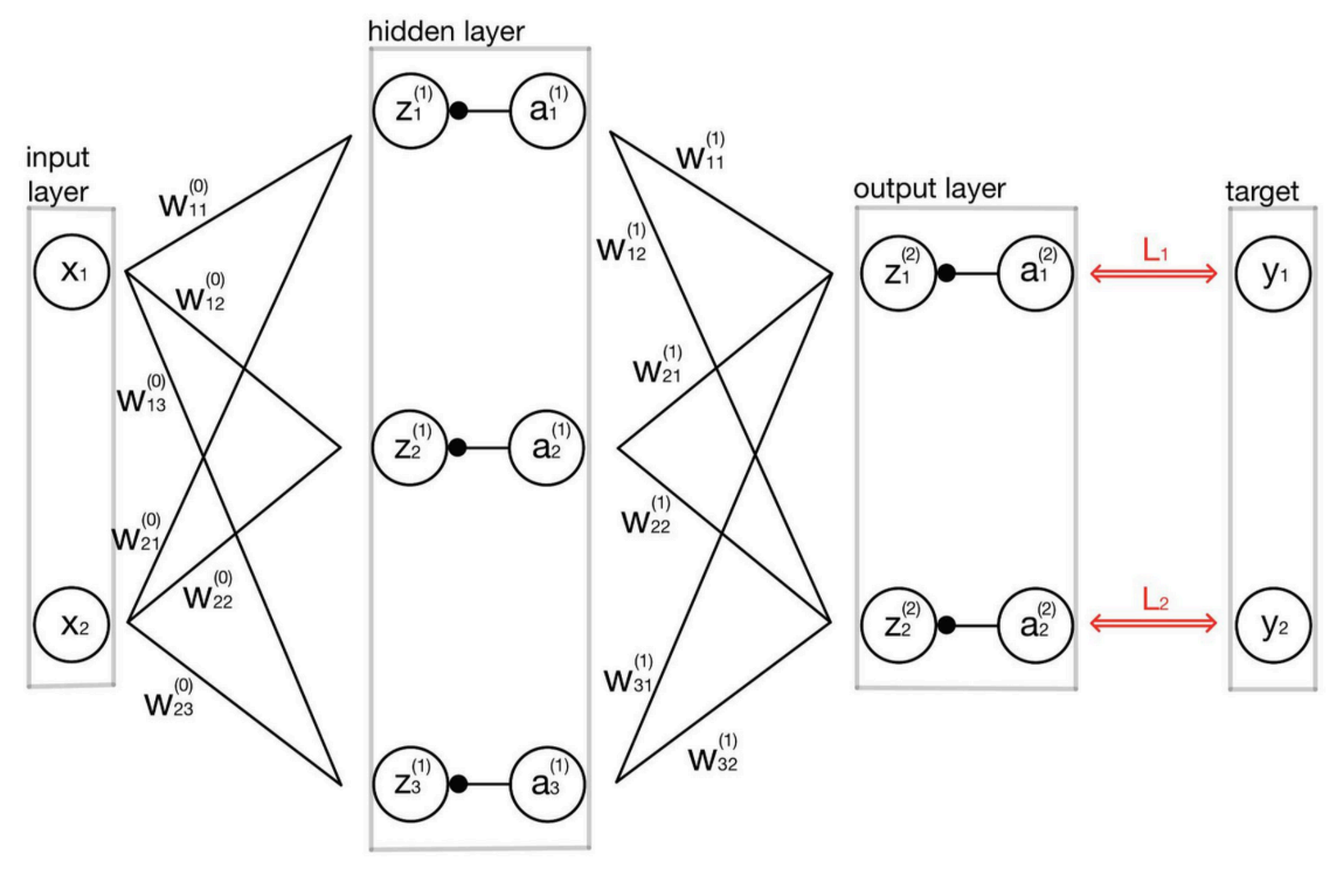
이를 해결하고자 등장한 것이

역전파 알고리즘

다층 퍼셉트론에서 가중치 갱신은 다음과 같은 단계로 수행됨

1) 신경망은 모든 연산이 입력층에서 출력층으로 이동함 → **순방향 신경망** 혹은 **순전파**
2) 입력층에 들어온 입력값을 순전파하여 **예측값**을 도출해냄
3) 타겟값과 예측값의 오차를 계산한 뒤 **역전파 알고리즘**을 이용하여 출력층에서 입력층으로 오차를 전파
   → 가중치가 갱신됨

역전파 알고리즘



다층 퍼셉트론에서 가중치 갱신의 자세한 설명

1) 최초 입력값은 활성화 함수를 거쳐 순전파를 통해 각 출력값을 계산한다.

2) 출력층의 노드에 있는 값과 타깃값의 차이를 이용하여 전체 손실을 구한다.

3) 역전파 알고리즘에 의해 출력층부터 시작하여 입력층으로 오차를 전파한다.

4) 오차가 전파되어 도달한 층의 가중치를 갱신한다. (갱신 공식은 아래와 같다.)

$$w = w - \alpha \times \frac{\partial L}{\partial w}$$

역전파 알고리즘

역전파 알고리즘의 장점

- 깊은 층을 갖는 신경망의 가중치를 효과적으로 갱신할 수 있음

역전파 알고리즘의 단점

- 경사 하강법의 기울기를 이용하여 오차를 줄이는 방법을 따르므로 항상 Global Minimum 으로 수렴할 것이라는 보장이 없음
- 모델의 층이 깊어질수록 기울기가 사라지는 **기울기 소실 현상**이 발생할 수 있음

감사합니다.